

Previsão de Churn de Clientes

Machine Learning aplicado à retenção em e-commerce (estrutura estilo Olist)

Autora: Ana Paula Galdino • Pós-graduação em Data Analytics (POSTECH/FIAP) • Junho de 2026

Sumário Executivo

Reter um cliente custa muito menos do que conquistar um novo. Este projeto desenvolve um modelo de **Machine Learning** que prevê quais clientes têm maior probabilidade de **churn** (deixar de comprar), a partir do comportamento de compra e da experiência de entrega de **6.000** clientes.


O melhor modelo (**Regressão Logística**) atinge **ROC AUC de 0.909** e acurácia de **82%**, com forte capacidade de separar clientes em risco dos clientes ativos — permitindo direcionar ações de retenção antes da perda, e não depois.

0.909	82%	49%	6.000
ROC AUC (Regressão Logística)	acurácia	taxa de churn na base	clientes analisados

1. Entendendo o Churn

A base apresenta uma taxa de churn de **49%**. O cruzamento com a satisfação é revelador: clientes com nota média baixa (1–2) têm **68%** de churn, contra apenas **39%** entre os mais satisfeitos (4.5–5). A experiência do cliente é, portanto, um preditor direto de retenção.


Distribuição do churn — taxa geral de 49.4%



Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino

Proporção de clientes ativos vs. churn

Taxa de churn por nota média de avaliação




Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino

Quanto menor a satisfação, maior o churn

2. Drivers de Negócio

A **recência** (tempo desde a última compra) é o fator mais associado ao churn: clientes parados há mais de 300 dias concentram as maiores taxas de saída. Em seguida vêm **satisfação** e **valor gasto**. Os três principais fatores do modelo são: **recência**, **satisfação (nota)**, **valor gasto**.


Taxa de churn por recência (dias desde a última compra)



Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino

Taxa de churn cresce com a recência

Variáveis que mais influenciam o churn



Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino


Importância das variáveis no modelo Random Forest

3. Desempenho do Modelo

Foram comparados dois algoritmos — Regressão Logística e Random Forest. O modelo **Regressão Logística** obteve o melhor equilíbrio (ROC AUC 0.909). A matriz de confusão mostra acertos

consistentes em ambas as classes, e a curva ROC confirma a forte separação entre clientes ativos e em risco.


Matriz de confusão — Regressão Logística



Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino

Acertos e erros do melhor modelo

Curva ROC — comparação de modelos



Dataset: e-commerce (estilo Olist) | Modelagem: Ana Paula Galdino

Curva ROC — quanto mais perto do topo esquerdo, melhor

Aplicação e Recomendações

- **Score de risco:** o modelo gera, para cada cliente, uma probabilidade de churn — base para uma régua de retenção priorizada.
- **Aja na recência:** clientes inativos há +300 dias devem receber campanhas de reativação imediatas.
- **Cuide da experiência:** como baixa satisfação dobra o churn, reduzir atrasos e melhorar o pós-venda tem impacto direto na retenção.
- **Próximo passo:** aplicar o pipeline aos dados reais da Olist (Kaggle) usando o mesmo esquema de features, e estimar o retorno financeiro da retenção.